

צינור היצירה (Pipeline) – צעד אחר צעד

מה קורה מהרגע שלוחצים על ✨ "צור אינפוגרפיקה" ועד שהדוח הסופי מוצג – כולל השלב הכפול שאתם רואים, לאן הולך הזמן, ואיך להאיץ את התהליך.

מבט-על: שלבי הצינור

■ מקומי – מיידי (אלפיות שנייה) ■ קריאה למודל – כאן הולך הזמן ■ לוגיקה/החלטה

1 בניית הבקשה

המערכת מרכיבה את הפנייה למודל: פרומפט המערכת (הכללים והחזרה מול המודל) + טקסט המסמך שחולץ + רמזים מבניים (כותרות, טבלאות כ-JSON) + הגדרות הפלט שלכם (ערכת צבעים, רמת פירוט, מספר תרשימים).

מקומי · מיידי

2 החלטה: מעבר אחד או שניים?

המערכת מעריכה את גודל המסמך בטוקנים ומשווה ל"תקציב ההקשר": חלון ההקשר של המודל (מההגדרות) פחות מקס' טוקנים לפלט פחות שולי ביטחון. אם המסמך נכנס – קפיצה ישירה לשלב 4. אם לא – עוברים דרך שלב 3.

מקומי · מיידי · נשלט על ידי "חלון הקשר של המודל" בהגדרות

3 שלב א' (מותנה): סיכום במקטעים

המסמך מפוצל למקטעים, וכל מקטע נשלח למודל בנפרד כדי לדחוס אותו לתקציר JSON מובנה (מספרים, ישויות, טבלאות – במדויק, בלי להמציא). התקצירים מאוחדים לתדריך אחד קומפקטי שמחליף את המסמך המלא. זהו "השלב הראשון" שאתם רואים בסרגל ההתקדמות.

קריאת מודל לכל מקטע · לרוב 30–90 שניות למקטע

4 שלב ב': יצירת הדוח (השלב הכבד)

המודל מקבל את המסמך (או התדריך) וכותב את מסמך ה-HTML המלא – כותרת, מקטעים, כרטיסי KPI, קוד תרשימים, תרשים זרימה – תוך הזרמה (streaming) שמוצגת כספירת טוקנים. דוח מלא הוא בדרך כלל 3,000–8,000 טוקנים של פלט.

קריאת מודל · רוב זמן ההמתנה – במודל מקומי בקצב 15–50 טוקן/שנ' זה 1–6 דקות

5 עיבוד-אחרי מקומי

ניקוי גדרות markdown אם המודל הוסיף, הזרקת ספריית התרשימים (Chart.js + התוספים), גיליון העיצוב, ערכת הצבעים והגופן המוטמע – הכול מתוך הקובץ עצמו, ללא רשת.

מקומי · מיידי

בדיקת תקינות (Lint) ותיקון (מותנה)

6

המערכת סורקת את הפניות חיצוניות אסורות? HTML שבור? תרשים בלי canvas? אם נמצאו בעיות – סבב תיקון יחיד מול המודל (הסטטוס יסומן "תוקן"). אם התיקון לא מושלם – הסרה מקומית קשיחה של ההפניות + אזהרה. קריאת מודל רק אם צריך · יכול להוסיף עוד דקות

הצגה ותיעוד

7

הדוח המוגמר מוצג ב-iframe מבודד (sandbox) – מנותק מהמפתחות ומהאחסון של המחולל – וכל המדדים (טוקנים, זמנים, מהירות, סטטוס) נרשמים בתפריט הביצועים. מקומי · מידי

אז מהם "שני השלבים" שאתם רואים?

אם סרגל ההתקדמות מציג שני שלבים, המסמך שלכם גדול מתקציב ההקשר, ולכן המערכת מפעילה את **המסלול הדו-שלבי**:

1. **שלב א' – סיכום**: דחיסת המסמך לתדריך JSON (קריאת מודל אחת לכל מקטע).
 2. **שלב ב' – יצירה**: כתיבת הדוח המלא מתוך התדריך (הקריאה הכבדה).
- לעיתים יופיע שלב שלישי – **תיקון** – אם הפלט הראשון לא עמד בכללים.

לאן באמת הולך הזמן?

כמעט כל ההמתנה היא **המודל שמייצר טוקנים** – לא המחולל. העיבוד המקומי (חילוץ, הזרקה, בדיקות, רינדור) הוא מידי.

רכיב	עלות זמן טיפוסית	ממה זה נובע
שלב הסיכום (אם רץ)	30–90 שני' למקטע	קריאת מודל לכל מקטע; מספר המקטעים תלוי בגודל המסמך מול חלון ההקשר
יצירת הדוח	1–6+ דקות	3,000–8,000 טוקני פלט בקצב המודל (15–50 טוק"/שני' במודל מקומי טיפוסי)
סבב תיקון (אם רץ)	עד כמו היצירה	המודל כותב את הדוח מחדש
כל השאר	שברירי שנייה	עיבוד מקומי בדפדפן

לראות במקום לנחש: פתחו  **ביצועים** ולחצו על הריצה – תראו לכל שלב (summarize / main / repair) את הטוקנים, זמן התגובה, ואת קצב הטוקנים לשנייה. זה מצביע בדיוק על צוואר הבקבוק.

איך להאיץ – לפי סדר ההשפעה

1. **בטלו את שלב הסיכום אם הוא מיותר**: ב-**הגדרות** ← **חיבור** ודאו ש"חלון הקשר של המודל" מוגדר לגודל האמיתי של המודל (למשל 32K או 128K). אם המסמך באמת נכנס לחלון – תקבלו מעבר אחד במקום שניים. לרוב זה החיסכון הגדול ביותר.
2. **בקשו פחות פלט**: ב-**הגדרות** ← **פלט** בחרו רמת פירוט "תמציתי" והקטינו את מספר התרשימים המרבי. פחות טוקנים = פחות זמן, כמעט ביחס ישר.
3. **צמצמו תיקונים**: סבב תיקון נגרם מפלט לא תקין (הפניות חיצוניות, HTML שבור). מודל חזק/מדויק יותר מקטין את תדירותם. בדקו בתפריט הביצועים אם הסטטוס "תוקן" חוזר על עצמו.

4. **המודל והחומרה הם התקרה:** קצב הטוקנים של השרת (מודל קטן/מהיר יותר, GPU חזק יותר, פחות עומס) הוא המנוף הגדול ביותר. שום דבר בצד הדפדפן לא יכול להאיץ את קצב הפליטה של המודל.

הערה כנה: הרצת מקטעי הסיכום במקביל נשמעת מפתה, אבל רוב שרתי המודלים המקומיים על GPU יחיד מעבדים בקשות בטור – מקביליות בדפדפן לא תקצר את הזמן בפועל ועלולה להעמיס על השרת.